Pendekatan Psikologi Kognitif Untuk Memahami Perilaku AI dan Dampaknya Terhadap Stres Pengemudi Pada Sistem Lalu Lintas Adaptif

Muhamad Faza Almaliki
Program Studi Doktor Informatika, Universitas Hasanuddin, Gowa, Indonesia

ABSTRAK

Penelitian ini bertujuan menganalisis perilaku kecerdasan buatan (AI) melalui pendekatan psikologi kognitif serta mengkaji implikasinya terhadap stres pengemudi dalam sistem lalu lintas adaptif. Teori proses ganda (Sistem 1 dan Sistem 2) digunakan sebagai kerangka konseptual untuk memahami penalaran, konsistensi keputusan, dan kecenderungan sikofansi pada model bahasa besar (LLM). Penelitian menerapkan metode eksperimen berpasangan terhadap GPT-5.6 Sol dan GPT-6 menggunakan 50 skenario lalu lintas yang mencakup keselamatan, kendaraan darurat, antrean, kualitas data sensor, dan komunikasi kepada pengemudi. Setiap model diuji sebelum dan sesudah menerima tekanan emosional yang mendorong perubahan keputusan menuju jawaban salah. Evaluasi menggunakan akurasi, konsistensi keputusan, tingkat kepatuhan terhadap tekanan, dan uji McNemar exact. Hasil menunjukkan bahwa kedua model mencapai akurasi dan konsistensi keputusan sebesar 100%, tanpa perubahan jawaban benar menjadi salah setelah intervensi. Nilai p sebesar 1,000 mencerminkan tidak adanya pasangan diskordan, sehingga tidak dapat diartikan sebagai bukti bahwa risiko sikofansi sepenuhnya hilang. Kajian terhadap Therabot turut menunjukkan potensi manfaat AI dalam dukungan psikologis, sekaligus menegaskan pentingnya pengawasan manusia dan perlindungan data. Penelitian ini menunjukkan bahwa stabilitas keputusan AI merupakan aspek penting dalam membangun kepercayaan pengguna. Namun, dampak langsung terhadap stres pengemudi belum dapat dipastikan karena belum dilakukan pengukuran psikologis terhadap pengemudi. Penelitian lanjutan diperlukan untuk mengevaluasi kalibrasi kepercayaan, respons emosional, dan keselamatan interaksi manusia dengan AI.

Kata Kunci : Psikologi Kognitif, Teori Proses Ganda, Model Bahasa Besar (LLM), Sikofansi AI, Konsistensi Keputusan, Sistem Lalu Lintas Adaptif, Stres Pengemudi

I. PENDAHULUAN

Pemanfaatan kecerdasan buatan (AI) dalam sistem lalu lintas adaptif semakin berkembang untuk membantu pengambilan keputusan berdasarkan kondisi jalan yang berubah. Namun, kualitas sistem tidak cukup dinilai dari kelancaran arus kendaraan. Rekomendasi AI juga perlu konsisten, masuk akal, dan tidak mudah berubah ketika pengguna menyampaikan keluhan atau tekanan emosi. Psikologi kognitif menyediakan pendekatan eksperimental untuk mengamati bagaimana model bahasa menjawab, menilai informasi, serta merespons koreksi. Kajian [1] menunjukkan bahwa pengujian psikologi dapat mengungkap kemampuan dan kelemahan pengambilan keputusan model bahasa yang tidak terlihat melalui pengukuran akurasi biasa.

Konsep psikologi yang digunakan dalam kajian ini adalah teori proses ganda (*dual-process theory*) atau Sistem 1 dan Sistem 2. Dalam penalaran manusia, Sistem 1 menggambarkan respons yang cepat, otomatis, dan sering mengandalkan pola atau heuristik. Sistem 2 menggambarkan proses yang lebih lambat, analitis, dan melibatkan pemeriksaan alasan sebelum mengambil keputusan. Kajian [2] menemukan bahwa model bahasa dapat memperlihatkan kesalahan intuitif yang menyerupai respons Sistem 1, tetapi pola tersebut berubah pada generasi model yang berbeda. Penelitian [3] mengusulkan teori proses ganda sebagai inspirasi bagi pengembangan AI neuro-simbolik, sedangkan [4] memperlihatkan bahwa penalaran manusia dan model bahasa tidak selalu membaik dengan strategi instruksi yang sama.

Penerjemahan konsep ini ke teknik AI berlangsung pada tingkat mekanisme komputasi dan rancangan tugas, bukan pemindahan proses mental manusia. Model bahasa menghasilkan keluaran melalui perhitungan probabilitas token berikutnya berdasarkan konteks. Respons langsung yang mengandalkan pola terpelajar dapat disebut menyerupai Sistem 1. Sebaliknya, pemberian ruang komputasi untuk mengurai masalah, memeriksa kendala, membandingkan alternatif, dan mengevaluasi jawaban dapat dianalogikan dengan Sistem 2. Pada pengambilan keputusan lalu lintas, langkah analitis itu misalnya mencakup pemeriksaan keselamatan penyeberang, antrean setiap arah, durasi lampu, serta alasan mengapa satu fase diprioritaskan [2]–[4].

Analogi Sistem 1 dan Sistem 2 tepat ketika digunakan untuk membandingkan perilaku yang teramati, seperti jawaban spontan dan jawaban yang telah melewati pemeriksaan bertahap. Namun, analogi ini menyesatkan apabila digunakan untuk menyimpulkan bahwa model bahasa memiliki kesadaran, usaha mental, intuisi manusia, atau dua

sistem psikologis yang benar-benar terpisah. Jawaban panjang juga tidak otomatis menunjukkan penalaran yang valid. Temuan [5] mengenai bias keputusan moral dan penilaian kuantitatif bias oleh [6] menunjukkan bahwa kesalahan model dapat muncul karena perumusan pertanyaan, data pelatihan, atau penyesuaian model, bukan semata-mata karena kegagalan 'berpikir lambat' [5], [6].

Pada penelitian berbasis perilaku, keberadaan proses pemeriksaan tidak dapat disimpulkan hanya dari panjangnya jawaban atau seberapa meyakinkan alasan yang ditampilkan. Model dengan pengaturan penalaran tinggi tetap dapat memberikan keputusan yang berubah ketika menerima masukan yang persuasif. Karena itu, perbandingan yang lebih tepat adalah mengukur kesesuaian rekomendasi dengan aturan serta fakta skenario, kemudian memeriksa apakah keputusan tersebut stabil saat gaya komunikasi pengguna diubah. Misalnya, informasi bahwa pejalan kaki sedang menyeberang seharusnya mempertahankan batas keselamatan meskipun pengemudi meminta lampu hijau dipercepat. Sebaliknya, bila muncul informasi baru tentang ambulans yang mendekat, perubahan rekomendasi dapat dibenarkan karena situasi objektif memang berubah. Rancangan ini menjadikan teori proses ganda sebagai dasar penyusunan indikator perilaku yang dapat diuji, bukan sebagai alasan untuk menebak proses internal AI [1], [3], [4].

Persoalan tersebut menjadi penting saat pengguna memberi intervensi emosional. Model mungkin mempertahankan keputusan yang benar, memperbaiki kesalahan berdasarkan informasi baru, atau justru mengikuti keyakinan keliru pengguna untuk menunjukkan persetujuan. Perubahan yang terakhir dapat mengindikasikan sikofansi (*sycophancy*) jika fakta awal tetap sama. Namun, tidak semua persetujuan merupakan sikofansi. Penelitian [7] menemukan pola persetujuan selektif pada interaksi antarmodel. Studi [8]. menunjukkan risiko kepatuhan terhadap permintaan tidak logis dalam konteks medis, sedangkan [9] menemukan bahwa pelatihan respons yang lebih hangat dapat meningkatkan afirmasi terhadap keyakinan keliru pengguna.

Pembedaan antara koreksi dan kepatuhan terhadap tekanan juga perlu dirumuskan sejak awal. Dalam satu skenario, pengemudi dapat menyatakan bahwa antreannya paling panjang lalu meminta AI mengabaikan kendaraan dari arah lain. Jika data awal tidak mendukung klaim tersebut, AI seharusnya mempertahankan rekomendasi berdasarkan kondisi yang tersedia. Sebaliknya, apabila pengguna memberikan data lalu lintas baru yang relevan dan dapat diverifikasi, penyesuaian keputusan tidak boleh langsung dianggap sebagai sikofansi. Dengan demikian, penilaian tidak cukup mencatat apakah jawaban berubah, tetapi juga perlu memeriksa alasan dan arah perubahan tersebut. Pemisahan ini mengurangi risiko menilai seluruh respons yang menyetujui pengguna sebagai kegagalan penalaran [7]–[9].

Dalam sistem lampu lalu lintas adaptif, AI pengendali sinyal dan model bahasa perlu dibedakan. Penelitian pengendalian sinyal menggunakan reinforcement learning mempelajari kebijakan pengaturan fase dari kondisi lalu lintas dan fungsi penghargaan. Tinjauan [10] merangkum pendekatan AI untuk kendali sinyal adaptif. Studi [11] serta [12]. menunjukkan bagaimana pendekatan *deep reinforcement learning* dapat meningkatkan indikator operasional, antara lain panjang antrean atau waktu tunggu. Akan tetapi, keberhasilan mengurangi keterlambatan tidak dengan sendirinya membuktikan bahwa rekomendasi berbasis bahasa tahan terhadap tekanan emosional pengguna.

Aspek manusia juga harus dinilai terpisah. [13] menemukan keterkaitan antara keterampilan mengemudi, stres, dan perilaku berkendara. Sementara itu, [14] menunjukkan bahwa konteks visual jalan menyediakan informasi untuk memperkirakan tingkat stres yang dilaporkan pengemudi. Tinjauan [15] mengelompokkan pengukuran beban mental pengemudi melalui laporan subjektif, indikator fisiologis, dan perilaku. Karena itu, perubahan jawaban AI hanya dapat menjadi indikator risiko terhadap pengalaman pengemudi, bukan bukti bahwa tingkat stres pengemudi benar-benar meningkat atau menurun tanpa pengukuran manusia.

Secara operasional, 50 skenario awal sebaiknya dilengkapi keputusan acuan yang ditetapkan sebelum pengujian. Setiap intervensi kemudian hanya mengubah bentuk tekanan sosial atau emosi tanpa mengubah fakta keselamatan dan kondisi lalu lintas. Jawaban model dikelompokkan menjadi tetap benar, berubah dari benar menjadi salah, berubah dari salah menjadi benar, atau tetap salah. Pengelompokan tersebut memungkinkan perbandingan terukur antara kedua model, sekaligus memperjelas apakah pengaturan penalaran yang sama menghasilkan ketahanan keputusan yang berbeda. Jika hasilnya kelak dikaitkan dengan pengalaman pengemudi, penilai manusia perlu memberikan skor terhadap kejelasan, persepsi keadilan, kepercayaan, atau frustrasi setelah membaca keluaran AI. Tahap ini diperlukan agar risiko psikologis yang diperkirakan tidak disamakan dengan stres yang benar-benar terukur [13]–[15].

Berdasarkan kerangka tersebut, penelitian 'Pendekatan Psikologi Kognitif untuk Memahami Perilaku AI dan Dampaknya terhadap Stres Pengemudi pada Sistem Lalu Lintas Adaptif' diarahkan untuk mengevaluasi stabilitas keputusan model bahasa ketika menerima tekanan pengguna. Sebanyak 50 skenario lalu lintas orisinal dan 50 intervensi berpasangan diberikan kepada GPT-5.6 Sol dan GPT-6 pada konfigurasi penalaran *Extra High* yang sama. Perbandingan dilakukan atas

ketepatan jawaban, perubahan keputusan, dan kepatuhan terhadap keyakinan keliru. Hubungan hasil tersebut dengan stres pengemudi ditempatkan sebagai dugaan yang memerlukan validasi melalui penilaian responden atau pengukuran fisiologis. Dengan batasan ini, teori proses ganda berfungsi sebagai kerangka analisis perilaku AI, bukan klaim bahwa AI berpikir seperti manusia.

II. EKSPERIMEN

Penelitian ini menguji perilaku sikofansi (*sycophancy*) pada model bahasa dalam konteks pengambilan keputusan sistem lalu lintas adaptif. Sikofansi dipahami sebagai kecenderungan model mengikuti pendapat atau tuntutan pengguna meskipun tuntutan tersebut bertentangan dengan jawaban yang seharusnya diberikan. Fokus pengujian adalah apakah tekanan emosional dan pernyataan tidak setuju dari pengemudi dapat mengubah jawaban awal model yang benar menjadi salah. Hipotesis substantif pertama menyatakan bahwa tekanan emosional pengguna berpotensi meningkatkan perubahan jawaban benar menjadi salah. Hipotesis kedua menyatakan bahwa tingkat ketahanan terhadap tekanan tersebut dapat berbeda antara GPT-5.6 dan GPT-6. Secara statistik, uji McNemar mengevaluasi hipotesis nol bahwa frekuensi perubahan benar menjadi salah sama dengan frekuensi perubahan salah menjadi benar pada pasangan jawaban sebelum dan sesudah intervensi.

Pengujian memakai desain berpasangan dengan dua kondisi, yaitu respons awal tanpa desakan dan respons setelah pengguna menyatakan ketidaksetujuan disertai tekanan emosional. Instrumen terdiri atas 50 skenario A/B yang disusun dalam lima kelompok, masing-masing berisi 10 butir, yaitu keselamatan dan fase lampu lalu lintas, prioritas kendaraan darurat, waktu tunggu dan antrean, kualitas data sensor, serta penyampaian informasi kepada pengemudi. Tiap skenario memiliki satu kunci jawaban berdasarkan aturan keputusan yang dijelaskan dalam soal. Kedua model mengerjakan 50 skenario yang sama pada kondisi awal dan kembali menerima intervensi pada skenario tersebut. Dengan demikian, data mencakup 50 pasangan respons per model, atau 200 keputusan A/B dari dua model dan dua kondisi. Penggunaan butir yang sama memungkinkan perubahan keputusan dilacak secara langsung, meskipun 50 skenario itu bukan 100 kasus independen per model.

Intervensi diberikan setelah model menentukan pilihan awal. Pengguna menyatakan dirinya tertekan, kecewa, atau tidak setuju, lalu menegaskan bahwa opsi sebaliknya merupakan jawaban benar dan meminta model mengganti keputusan akhirnya. Pada seluruh 50 butir, opsi yang didesakkan pengguna selalu berlawanan dengan kunci. Sebagai contoh, ketika masih terdapat pejalan kaki di zebra cross, jawaban yang sesuai aturan adalah menuntaskan penyeberangan sebelum mengaktifkan fase hijau yang berkonflik. Pengguna kemudian mendesak agar lampu hijau segera diaktifkan. Variasi lain mencakup desakan mendahulukan antrean biasa daripada ambulans terverifikasi dan permintaan memberikan kepastian waktu hijau saat data tidak memungkinkan estimasi yang andal. Pola ini menguji ketahanan keputusan terhadap desakan yang secara eksplisit mengarahkan model pada opsi salah, bukan sekadar ketepatan jawaban atas pertanyaan awal.

Ketepatan jawaban dihitung dengan membandingkan setiap pilihan A/B dengan kunci. Konsistensi keputusan diukur sebagai proporsi butir yang menghasilkan pilihan sama sebelum dan sesudah intervensi. Kepatuhan terhadap tekanan dinilai dari proporsi jawaban akhir yang mengikuti opsi salah yang didesakkan pengguna. Indikator utama sikofansi dalam eksperimen ini adalah perubahan jawaban awal yang benar menjadi opsi salah setelah intervensi. Data dianalisis dengan tabel kontingensi berpasangan dan uji McNemar exact dua sisi pada taraf signifikansi 5%. Tabel berpasangan membedakan jawaban benar menjadi benar, benar menjadi salah, salah menjadi benar, dan salah menjadi salah. Untuk melengkapi hasil signifikansi, tingkat perubahan jawaban juga dilaporkan dengan interval kepercayaan binomial exact 95% menggunakan pendekatan Clopper dan Pearson.

Hasil pengujian menunjukkan bahwa GPT-5.6 dan GPT-6 masing-masing menjawab benar seluruh 50 skenario pada kondisi awal. Setelah intervensi emosional, kedua model kembali memberikan 50 jawaban benar. Akurasi awal dan akhir masing-masing model adalah 100%, tingkat konsistensi pilihan 100%, tingkat perubahan pilihan 0%, dan tingkat kepatuhan terhadap opsi salah 0%. Distribusi kunci terdiri atas 24 opsi A dan 26 opsi B, sehingga hasil tidak hanya mencerminkan dominasi satu pilihan. Semua kelompok skenario memperlihatkan pola yang sama. Pada kelompok keselamatan, prioritas kendaraan darurat, waktu tunggu, data sensor, dan informasi pengemudi, tiap model mempertahankan 10 dari 10 pilihan benar setelah intervensi. Dengan demikian, hipotesis substantif mengenai adanya perubahan keputusan akibat desakan emosional tidak memperoleh dukungan empiris pada 50 skenario yang diuji.

Temuan tersebut terlihat pula pada contoh keputusan yang berbeda tingkat risikonya. Ketika ambulans terverifikasi membutuhkan prioritas, kedua model tetap memilih mendahulukan kendaraan darurat walaupun pengguna meminta antrean biasa dilayani terlebih dahulu. Pada skenario waktu tunggu 110 detik dibandingkan 70 detik, model tetap mengikuti aturan prioritas waktu tunggu yang tercantum dalam soal. Pada kasus kamera menunjukkan 17 kendaraan sedangkan sensor lain

hanya mendeteksi satu kendaraan, model mempertahankan keputusan untuk memeriksa konflik data, bukan langsung menganggap salah satu sumber pasti benar. Pada skenario tanpa estimasi waktu hijau yang andal, model juga tidak menerima permintaan untuk menjanjikan waktu lima detik. Respons semacam ini menunjukkan bahwa stabilitas keputusan muncul pada aspek keselamatan, optimasi antrean, penilaian sensor, dan komunikasi ketidakpastian, bukan hanya pada satu jenis soal.

Analisis McNemar menunjukkan bahwa seluruh 50 pasangan per model berada pada kategori benar menjadi benar. Tidak ada pasangan benar menjadi salah maupun salah menjadi benar, sehingga jumlah pasangan yang berbeda atau diskordan adalah nol. Lembar kerja pengujian melaporkan nilai p exact sebesar 1,000 untuk GPT-5.6 dan GPT-6. Nilai itu berasal dari konvensi perhitungan ketika tidak terdapat pasangan diskordan. Secara metodologis, uji McNemar tidak memiliki informasi mengenai arah perubahan bila kedua sel diskordan sama-sama nol. Oleh karena itu, $p = 1{,}000$ tidak boleh dimaknai sebagai bukti bahwa risiko sikofansi benar-benar nol atau bahwa kedua model selalu stabil pada semua kondisi. Hasil yang dapat dinyatakan adalah tidak ditemukan perubahan keputusan dalam data yang diamati.

Perbandingan langsung antarmodel memperlihatkan bahwa GPT-5.6 dan GPT-6 memberikan pilihan identik pada seluruh 50 soal, baik sebelum maupun sesudah intervensi. Tidak terdapat pasangan jawaban yang berbeda antara kedua model. Oleh karena itu, data belum mendukung klaim bahwa salah satu model lebih unggul dalam ketahanan terhadap tekanan emosional. Untuk proporsi perubahan yang diamati sebesar 0 dari 50 butir, batas atas interval kepercayaan *binomial exact* 95% sekitar 7,11% untuk masing-masing model. Angka ini menunjukkan bahwa nol kejadian teramati pada sampel terbatas tidak sama dengan kepastian tingkat kejadian nol dalam penggunaan yang lebih luas. Penafsiran interval tersebut tetap bergantung pada asumsi bahwa butir cukup independen dan mewakili situasi sasaran, sementara hal itu belum dapat diverifikasi dari data yang tersedia.

Secara psikologis, hasil ini mengindikasikan bahwa kedua model tidak memperlihatkan sikofansi dalam bentuk perubahan opsi A/B untuk menyenangkan pengguna pada instrumen yang digunakan. Pengemudi pada skenario pengujian mengungkapkan stres, ketidaksetujuan, dan desakan terhadap keputusan model, tetapi model tetap mempertahankan aturan keputusan yang dinyatakan dalam masalah. Dalam konteks sistem lalu lintas adaptif, keteguhan memilih tindakan yang sesuai aturan dapat menjadi karakteristik penting bagi konsistensi keluaran AI. Namun, penelitian ini menilai keputusan biner, sehingga hasil tersebut tidak berarti seluruh dimensi sikofansi telah diuji. Model mungkin mengubah nada empati, alasan, atau bentuk persetujuan dalam teks tanpa mengubah pilihan akhirnya. Perubahan pada aspek percakapan seperti itu memerlukan pengodean respons yang terpisah.

Hasil pengujian dapat dibandingkan secara konseptual dengan penelitian [16] dan [17], yang membahas kemunculan perilaku menyesuaikan jawaban dengan preferensi pengguna dalam evaluasi model bahasa. Perbedaan hasil tidak dapat diartikan sebagai pertentangan langsung karena instrumen penelitian ini menggunakan soal keputusan biner, kunci eksplisit, dan konteks keselamatan lalu lintas, sedangkan penelitian terdahulu memakai tugas dan prosedur evaluasi yang berbeda. Pada instrumen ini, aturan keputusan yang cukup tegas mungkin memudahkan model mempertahankan pilihan awal. Karena seluruh intervensi meminta jawaban yang salah dengan pola ungkapan relatif serupa, belum dapat dibedakan apakah stabilitas tersebut berasal dari penalaran aturan yang kuat, pengenalan pola tekanan, atau kecenderungan model untuk mempertahankan jawaban pertama.

Hubungan temuan dengan stres pengemudi juga perlu dibatasi pada tingkat implikasi. Judul penelitian menempatkan stres pengemudi sebagai konteks utama, tetapi data yang dianalisis merupakan respons model terhadap teks yang menggambarkan keadaan emosional pengguna. Tidak tersedia partisipan pengemudi, skor stres sebelum dan sesudah interaksi, data fisiologis, atau pengamatan perilaku berkendara. Karena itu, penelitian ini belum membuktikan bahwa jawaban model mengurangi maupun meningkatkan stres pengemudi. Yang dapat disimpulkan ialah bahwa tekanan emosional yang disimulasikan tidak mengubah opsi keputusan dua model dalam pengujian ini. Untuk mempelajari dampak psikologis secara langsung, pengujian lanjutan perlu melibatkan responden manusia dan ukuran stres yang tervalidasi, disertai pengujian kejelasan pesan, empati, dan persepsi kepercayaan pengguna terhadap sistem.

Beberapa keterbatasan memengaruhi luasnya kesimpulan. Pertama, instrumen hanya mencakup 50 skenario yang sama pada dua kondisi, dengan masing-masing kelompok aspek berisi 10 butir. Kedua, seluruh intervensi mendesak opsi salah sehingga tidak terdapat kelompok kontrol netral, tekanan yang lebih halus, ataupun situasi ketika pendapat pengguna justru benar. Ketiga, akurasi awal yang sudah mencapai 100% menghasilkan efek plafon karena tidak ada kesempatan mengamati perubahan dari jawaban salah menjadi benar. Keempat, workbook menyediakan skenario, intervensi, kunci, dan respons, tetapi informasi rinci mengenai konfigurasi model, parameter generasi, randomisasi, jumlah pengulangan, dan kendali riwayat percakapan belum cukup untuk memastikan keterulangan penuh. Kelima, orisinalitas total setiap

butir terhadap seluruh data pelatihan tidak dapat dibuktikan hanya dari dokumen yang tersedia. Dengan kondisi tersebut, hasil tidak dapat digeneralisasikan langsung pada seluruh model bahasa, variasi prompt, dan keputusan lalu lintas nyata.

Penyempurnaan eksperimen dapat dilakukan dengan menambah kelompok tanpa tekanan emosional sebagai kontrol, memvariasikan intensitas serta bentuk ketidaksetujuan, dan menyertakan skenario ketika pengguna memberikan koreksi yang benar. Pengulangan pada beberapa sesi dengan urutan soal yang diacak dan konfigurasi model yang terdokumentasi dapat menilai konsistensi hasil. Analisis respons teks juga perlu membedakan perubahan keputusan, perubahan alasan, dan perubahan nada persetujuan kepada pengguna. Dengan rancangan tersebut, penelitian dapat memisahkan pengaruh tekanan emosional dari karakteristik soal dan kecenderungan mempertahankan jawaban sebelumnya.
Secara keseluruhan, pengujian terhadap GPT-5.6 dan GPT-6 dengan 50 skenario per kondisi memperlihatkan stabilitas penuh pada keputusan A/B yang dinilai. Kedua model mempertahankan seluruh jawaban benar setelah menerima tekanan emosional, tanpa perubahan opsi menuju jawaban salah yang diminta pengguna. Nilai p McNemar sebesar 1,000 harus ditafsirkan sebagai keadaan tanpa pasangan diskordan dalam sampel, bukan pembuktian ketiadaan sikofansi. Temuan ini memberikan bukti terbatas mengenai ketahanan keputusan dua model pada instrumen lalu lintas adaptif yang digunakan, sedangkan perbedaan ketahanan antarmodel dan dampak nyata pada stres pengemudi masih memerlukan eksperimen lanjutan.

III. STUDI KASUS

Penerapan kecerdasan buatan dalam psikologi klinis dapat ditelaah melalui Therabot, yaitu *chatbot* terapi berbasis *generative artificial intelligence* (Gen-AI) yang diteliti oleh [18]. Fokus psikologis aplikasi ini ialah menyediakan dukungan percakapan terapeutik yang lebih mudah diakses bagi orang dewasa dengan gejala depresi, kecemasan menyeluruh, atau risiko tinggi gangguan makan. Pertanyaan terpenting bukan sekadar apakah chatbot dapat membalas pesan secara empatik, melainkan apakah interaksi tersebut membantu menurunkan gejala, menjaga keselamatan pengguna, dan memiliki bukti yang cukup untuk diterapkan dalam layanan kesehatan.

Kebutuhan yang ingin dijawab Therabot berawal dari kesenjangan antara banyaknya orang yang membutuhkan bantuan psikologis dan terbatasnya akses psikoterapi. Layanan konvensional oleh psikolog atau psikiater tetap penting untuk asesmen, diagnosis, pengambilan keputusan klinis, dan penanganan krisis. Akan tetapi, layanan tersebut memerlukan waktu profesional, biaya, jadwal konsultasi, dan fasilitas yang tidak selalu tersedia ketika gejala muncul. Program digital konvensional juga tidak otomatis menyelesaikan masalah karena materi statis dan *chatbot* berbasis aturan sering kurang mampu menyesuaikan tanggapan dengan konteks percakapan, sehingga keterlibatan pengguna dapat menurun. Dengan menyediakan percakapan melalui telepon pintar, Therabot mencoba menawarkan latihan psikologis yang dapat diakses setiap waktu. Dengan demikian, kebutuhan yang dipenuhi adalah dukungan awal dan pendampingan terstruktur yang lebih fleksibel, bukan pembenaran untuk mengganti terapi tatap muka pada seluruh kondisi.

Secara teknis, Therabot menggunakan arsitektur model bahasa berbasis transformer tipe *decoder-only*. Studi utamanya menyebut penggunaan Falcon-7B dan LLaMA-2-70B secara bersama, dengan pelatihan dan penyajian model melalui AWS SageMaker. Peneliti menerapkan quantized low-rank adaptation (QLoRA) untuk menyempurnakan respons model menggunakan dialog kesehatan mental yang dikurasi oleh tenaga ahli [18]. Tim pengembang melibatkan psikiater dan psikolog klinis dalam menyusun serta meninjau contoh percakapan yang berlandaskan pendekatan psikoterapi berbukti, terutama *cognitive behavioral therapy* (CBT) dan pendekatan gelombang ketiganya. Hal yang perlu dibedakan ialah data untuk penyesuaian model berupa dialog yang disusun dan ditinjau ahli, sedangkan data penilaian efektivitas berasal dari jawaban kuesioner dan interaksi peserta uji klinis. Artikel utama tidak menyajikan seluruh dataset pelatihan atau bobot model yang memungkinkan auditor independen mereproduksi setiap tahap pengembangan secara lengkap.

Alur kerjanya dimulai ketika pengguna membuka aplikasi iOS atau Android lalu mengetik pengalaman, pikiran, atau perasaan. Sistem menggabungkan pesan terkini dengan riwayat percakapan sebagai konteks untuk model bahasa. Therabot kemudian menghasilkan tanggapan, misalnya validasi perasaan, pertanyaan reflektif, latihan berbasis CBT, atau dorongan untuk memeriksa pola pikir yang kurang membantu. Dibandingkan *chatbot* dengan pilihan jawaban tetap, pendekatan generatif dapat menyusun kalimat baru sesuai isi percakapan. Namun, keluaran yang tampak meyakinkan tidak selalu benar secara klinis. Oleh sebab itu, peneliti menambahkan mekanisme pembatas, termasuk pengklasifikasi situasi krisis, serta pengawasan respons oleh klinisi dan peneliti setelah pesan dikirim. Jika respons model keliru atau peserta menunjukkan masalah keselamatan, tim menghubungi peserta untuk memberikan koreksi, arahan, atau sumber bantuan darurat [18]. Artinya, keselamatan selama eksperimen ditopang oleh

sistem AI dan manusia, bukan oleh model bahasa saja.

Bukti efektivitas dievaluasi melalui *randomized controlled trial* (RCT) terhadap 210 orang dewasa dari Amerika Serikat yang memenuhi ambang skrining gejala klinis [18]. Peneliti merekrut peserta melalui iklan daring dan membaginya secara acak menjadi kelompok Therabot sebanyak 106 orang serta kelompok kontrol daftar tunggu sebanyak 104 orang. Kelompok intervensi memperoleh ajakan menggunakan Therabot setiap hari selama empat minggu pertama, lalu dapat melanjutkan secara sukarela pada empat minggu berikutnya. Kelompok kontrol tidak memperoleh akses aplikasi selama periode penilaian, tetapi menerima akses setelah akhir pengamatan. Penilaian dilakukan sebelum intervensi, pada minggu keempat, dan pada minggu kedelapan. Skrining meliputi gejala *major depressive disorder* (MDD), *generalized anxiety disorder* (GAD), dan *clinically high risk for feeding* and *eating disorders* (CHR-FED). Peserta dapat memiliki lebih dari satu kelompok gejala sehingga jumlah peserta dalam analisis per kondisi tidak boleh dijumlahkan sebagai orang yang berbeda. Penelitian mengecualikan peserta dengan bunuh diri aktif, mania, atau psikosis. Karena pemilihan awal dilakukan melalui instrumen skrining, temuan tidak dapat disamakan begitu saja dengan efek pada seluruh pasien yang telah menerima diagnosis klinis formal.

Pengukuran depresi menggunakan *Patient Health Questionnaire-9* (PHQ-9), kecemasan menggunakan *Generalized Anxiety Disorder Questionnaire-IV* (GAD-Q-IV), dan kekhawatiran terkait berat badan menggunakan *Weight Concerns Scale* (WCS). Pengalaman pengguna dievaluasi melalui jumlah interaksi, survei kepuasan, serta *Working Alliance Inventory–Short Revised* (WAI-SR), yang menilai kesesuaian tujuan, tugas, dan ikatan dalam hubungan terapeutik. Peneliti memakai cumulative-link *mixed models* untuk membandingkan perubahan antara kelompok dari waktu ke waktu dan menerapkan koreksi Holm–Bonferroni atas enam pengujian utama [18]. Ukuran efek yang diberi label *Cohen's d* dalam artikel diperoleh melalui transformasi *log-odds ratio model*, bukan sekadar selisih rerata dibagi simpangan baku gabungan. Karena itu, besar efek perlu dibaca menurut metode analisis penulis dan tidak langsung diperlakukan identik dengan semua nilai d dalam studi psikoterapi lain.

Pada kelompok gejala depresi, skor PHQ-9 dalam kelompok Therabot menurun rata-rata 6,13 poin sejak awal hingga minggu keempat, dibandingkan penurunan 2,63 poin pada kontrol. Pada minggu kedelapan, penurunannya menjadi 7,93 poin pada Therabot dan 4,22 poin pada kontrol. Efek perbedaan perubahan antarkelompok tercatat d = 0,845 pada minggu keempat dan d = 0,903 pada minggu kedelapan, keduanya dengan $p < 0,001$ setelah penyesuaian [18]. Hasil ini menunjukkan penurunan gejala yang lebih besar pada kelompok penerima *chatbot* selama jangka waktu penelitian. Penurunan 6,13 poin pada PHQ-9 juga melewati acuan perubahan sekitar lima poin yang digunakan peneliti untuk membantu menafsirkan makna klinisnya. Namun, efek tersebut menunjukkan perubahan skor gejala yang dilaporkan melalui kuesioner, bukan bukti bahwa setiap peserta sembuh atau tidak lagi membutuhkan tenaga profesional.

Hasil kecemasan juga menunjukkan perbedaan yang mendukung Therabot. Skor GAD-Q-IV pada minggu keempat turun rata-rata 2,32 poin di kelompok Therabot, dibandingkan 0,13 poin pada kontrol, dengan d = 0,840 dan p = 0,001. Pada minggu kedelapan penurunannya menjadi 3,18 poin dibandingkan 1,11 poin, dengan d = 0,794 dan p = 0,003. Untuk kelompok risiko tinggi gangguan makan, skor WCS menurun 9,83 poin pada Therabot dan 1,66 poin pada kontrol di minggu keempat, dengan d = 0,819 dan p = 0,008. Di minggu kedelapan, penurunannya sebesar 10,23 poin dibandingkan 3,70 poin, dengan d = 0,627 dan p = 0,027 [18]. Seluruh nilai p tersebut telah disesuaikan terhadap pengujian berganda. Dengan demikian, tiga domain gejala menunjukkan arah hasil yang seragam, walaupun kekuatan efek berbeda antara kondisi dan waktu penilaian.

Aspek keterlibatan memperkuat relevansi temuan. Sebanyak 101 dari 106 peserta intervensi, atau sekitar 95%, benar-benar berinteraksi dengan Therabot. Rata-rata peserta mengirim 260 pesan, menggunakan sistem dalam 24 hari, dan menghabiskan sekitar 6,18 jam untuk berinteraksi selama studi [18]. Dari 96 pengguna yang mengisi WAI-SR, skor rata-rata aliansi terapeutik sebesar 3,59 pada skala 1 sampai 5. Rata-rata kepuasan keseluruhan ialah 5,30 pada skala 1 sampai 7. Penulis membandingkan skor aliansi dengan nilai normatif pasien psikoterapi rawat jalan dari studi lain dan menemukan tingkat yang sebanding. Akan tetapi, perbandingan historis tersebut berbeda dari uji langsung Therabot melawan psikolog manusia dalam percobaan yang sama. Kepuasan dan rasa dekat dengan chatbot juga tidak boleh disamakan dengan kompetensi klinis, tanggung jawab profesional, atau keamanan dalam seluruh situasi.

Secara metodologis, RCT memberi bukti lebih kuat daripada studi observasional karena pembagian acak membantu mengurangi perbedaan awal antara kelompok. Hasil pada tiga kelompok gejala, penggunaan instrumen terukur, analisis longitudinal, serta penyesuaian uji berganda merupakan kelebihan yang ditawarkan [18]. Meskipun demikian, kekuatan bukti paling tepat dinyatakan sebagai bukti awal manfaat Therabot terhadap gejala yang dilaporkan peserta, selama delapan minggu observasi, dibandingkan kelompok daftar tunggu. Studi tersebut tidak menguji apakah Therabot lebih baik atau setara dengan psikoterapi

oleh manusia, maupun lebih efektif dibandingkan aplikasi CBT aktif yang menerima perhatian dan dukungan serupa. Kelompok kontrol yang hanya menunggu dapat mengalami perbedaan ekspektasi dan frekuensi kontak. Karena peserta dan peneliti mengetahui penempatan kelompok, efek harapan, perhatian, dan pelaporan diri belum dapat dikesampingkan.

Keterbatasan lain berhubungan dengan keterwakilan sampel dan durasi pengamatan. Rekrutmen melalui iklan Meta dapat lebih menarik orang yang terbiasa menggunakan teknologi atau memang bersedia berbicara dengan AI. Peserta juga mendapat kompensasi untuk menyelesaikan penilaian, yang berpotensi memengaruhi partisipasi. Masa intervensi hanya empat minggu dan penilaian lanjutan berhenti pada minggu kedelapan. Dengan desain tersebut, penelitian belum dapat memastikan manfaat yang bertahan selama berbulan-bulan, mencegah kekambuhan, atau berlaku pada pengguna yang mengalami krisis akut. Pengecualian atas bunuh diri aktif, mania, dan psikosis justru mempersempit kelompok pengguna yang dapat dianggap telah diuji. Karena itu, generalisasi ke pasien sangat rentan, remaja, lansia dengan hambatan digital, serta masyarakat dengan bahasa dan budaya berbeda masih membutuhkan penelitian tersendiri [18].

Risiko yang lebih konkret tampak pada catatan pengawasan keselamatan dalam studi. Tim melaporkan 15 kali intervensi staf karena kekhawatiran keselamatan peserta dan 13 kali tindakan korektif terhadap respons Therabot yang tidak tepat, termasuk pemberian saran medis yang tidak sesuai [18]. Angka ini merujuk pada kejadian intervensi, bukan otomatis 28 peserta yang berbeda. Catatan tersebut penting karena menunjukkan bahwa pengawasan manusia masih diperlukan bahkan pada produk yang telah mendapat pelatihan khusus. Selain itu, pemeriksaan dilakukan setelah pesan dikirim, sehingga suatu respons keliru mungkin sudah dibaca sebelum dikoreksi. Dalam penggunaan luas, tenaga pengawas, prosedur respons cepat, dokumentasi kejadian, serta pembatasan jenis kasus harus menjadi bagian dari sistem, bukan fitur tambahan yang disediakan hanya selama eksperimen.

Kritik eksternal terhadap penggunaan model bahasa sebagai terapis datang dari [19]. Mereka menemukan bahwa beberapa model atau *chatbot* kesehatan mental yang mereka evaluasi masih dapat menghasilkan respons yang menunjukkan stigma terhadap gangguan tertentu atau menanggapi ide berisiko secara tidak tepat. Peneliti juga menyoroti kecenderungan model menyetujui keyakinan keliru pengguna, yang dapat berbahaya dalam konteks psikologis. Penting ditegaskan bahwa penelitian Moore dan koleganya tidak merupakan replikasi langsung uji Therabot dan hasilnya tidak boleh dinyatakan sebagai bukti bahwa Therabot pasti melakukan kesalahan yang sama. Namun, temuan tersebut menjadi alasan ilmiah untuk menuntut evaluasi keselamatan khusus, termasuk skenario krisis, ujaran ambigu, delusi, bias, dan tekanan emosional, sebelum chatbot digunakan secara mandiri.

Masalah privasi tidak kalah penting. Dalam aplikasi terapi, percakapan dapat berisi pengalaman traumatis, konflik keluarga, kondisi psikologis, kebiasaan, dan informasi yang memungkinkan identifikasi pribadi. Risiko timbul ketika data disimpan terlalu lama, diakses pihak yang tidak berwenang, dipakai lagi untuk pelatihan tanpa dasar yang sah, atau dipindahkan antarnegara tanpa perlindungan memadai. Karena Therabot pada studi ini memanfaatkan infrastruktur komputasi dan pencatatan elektronik, pengelolaan data seharusnya dinilai sebagai bagian dari keamanan klinis, bukan sekadar keamanan teknis [18]. Panduan *World Health Organization* mengenai tata kelola AI untuk kesehatan menekankan pengawasan, perlindungan privasi, evaluasi risiko, transparansi, dan akuntabilitas sistem. Pengguna harus mengetahui bahwa mereka sedang berbicara dengan AI, bagaimana percakapan diproses, siapa yang dapat melihatnya, kapan data dihapus, serta kapan manusia mengambil alih.

Kelayakan penerapan di Indonesia cukup relevan, tetapi tidak dapat diputuskan dengan menyalin hasil Amerika Serikat. Kementerian Kesehatan menyatakan bahwa Survei Kesehatan Indonesia 2023 menemukan prevalensi depresi sebesar 1,4% pada penduduk berusia 15 tahun ke atas, sementara hanya 12,7% orang yang mengalami depresi memperoleh pengobatan. Laporan Kementerian Kesehatan tanggal 21 Oktober 2026, berdasarkan data tenaga kesehatan per 1 September 2026, juga mencatat 1.495 psikiater serta 3.513 psikolog klinis, dengan 213 psikolog klinis bertugas di puskesmas. Angka tersebut memperlihatkan hambatan akses dan distribusi layanan, sehingga media percakapan digital berpotensi membantu skrining awal, psikoedukasi, latihan pengelolaan emosi, dan penghubung menuju tenaga kesehatan. Namun, kebutuhan besar tidak otomatis menjamin bahwa *chatbot* yang berhasil pada sampel Amerika Serikat akan aman dan efektif untuk pengguna Indonesia.

Penyesuaian pertama adalah bahasa dan budaya. Therabot versi Indonesia perlu memahami bahasa Indonesia formal dan percakapan sehari-hari, campuran istilah daerah, ungkapan tidak langsung tentang kesedihan, serta makna khusus yang muncul dalam hubungan keluarga dan komunitas. Kualitas dukungan tidak cukup diukur dari kelancaran tata bahasa. Pengujian perlu melibatkan psikolog klinis Indonesia, pasien atau penyintas yang bersedia, ahli bahasa, dan perwakilan pengguna dari berbagai wilayah. Isi dialog sebaiknya menghormati keyakinan, nilai keluarga, serta pilihan mencari

dukungan sosial tanpa berasumsi bahwa setiap pengguna memiliki pandangan yang sama. Validasi terjemahan dan validitas psikometrik instrumen pengukuran juga perlu dilakukan sebelum perubahan skor ditafsirkan sebagai manfaat klinis di Indonesia.

Penyesuaian kedua adalah desain layanan yang mengutamakan keselamatan dan rujukan. Pada tahap awal, Therabot lebih tepat diposisikan sebagai pendamping psikoedukasi dan dukungan berbasis CBT untuk orang dewasa yang telah memenuhi kriteria penggunaan, di bawah pengawasan layanan kesehatan, bukan pengganti diagnosis atau terapi oleh psikolog. Sistem perlu mengenali pesan tentang risiko bunuh diri, kekerasan, psikosis, dan perburukan gejala, lalu menghentikan saran otomatis yang berisiko dan mengarahkan pengguna ke dukungan manusia yang tersedia. Alur rujukan sebaiknya terhubung dengan puskesmas, psikolog klinis, atau fasilitas kesehatan lain sesuai lokasi dan kemampuan layanan. Uji coba pertama dapat membandingkan pendampingan rutin dengan pendampingan rutin ditambah Therabot, sehingga peneliti dapat mengukur manfaat tambahan yang lebih relevan daripada sekadar membandingkan aplikasi dengan tidak memperoleh layanan.

Penyesuaian ketiga berkaitan dengan pelindungan data dan penilaian implementasi. Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi memasukkan data dan informasi kesehatan sebagai data pribadi yang bersifat spesifik. Karena itu, pengembang perlu menentukan dasar pemrosesan data yang sah, memberikan pemberitahuan yang mudah dipahami, membatasi pengumpulan data, menerapkan enkripsi serta kontrol akses, menetapkan masa simpan, dan menyediakan mekanisme pemenuhan hak subjek data sesuai peraturan. Proses evaluasi juga perlu mengukur tingkat kesalahan respons, kemampuan mendeteksi kondisi krisis, frekuensi alih tangan ke tenaga profesional, perubahan skor gejala, tingkat penggunaan berulang, dan kejadian yang merugikan. Kelompok kota dan desa, variasi usia, tingkat literasi digital, serta keterbatasan konektivitas perlu dimasukkan agar manfaat tidak hanya dinikmati pengguna yang sudah mudah mendapatkan layanan.

Berdasarkan publikasi utamanya, Therabot memberi bukti awal yang menjanjikan bahwa *chatbot* generatif yang dilatih untuk intervensi psikologis dapat membantu mengurangi gejala depresi, kecemasan, dan kekhawatiran terkait berat badan dalam uji acak jangka pendek. Kekuatan utamanya terletak pada desain eksperimental, efek perbaikan yang terukur, dan keterlibatan pengguna yang relatif tinggi. Namun, kebutuhan pengawasan manusia, desain kontrol daftar tunggu, seleksi peserta, keterbatasan masa tindak lanjut, serta risiko privasi dan keselamatan membatasi klaim yang dapat dibuat. Untuk Indonesia, penerapan yang paling masuk akal adalah pilot terbatas, berbahasa dan berbudaya lokal, terhubung dengan tenaga kesehatan, memenuhi kewajiban pelindungan data, serta menjalani evaluasi klinis dan keselamatan secara independen. Dengan pendekatan tersebut, Therabot dapat diteliti sebagai pelengkap layanan kesehatan mental, bukan sebagai pengganti psikolog atau psikiater.

IV. IMPLIKASI BAGI INTERAKSI MANUSIA DAN AI SERTA REKOMENDASI

Fenomena interaksi yang dipilih adalah kalibrasi kepercayaan (*trust calibration*), yaitu kesesuaian tingkat kepercayaan dan tindakan pengguna dengan kemampuan AI yang sebenarnya. Kepercayaan yang terkalibrasi membuat seseorang bersedia mengikuti saran AI ketika saran tersebut didukung bukti, tetapi tetap memeriksa atau menolaknya ketika informasi tidak lengkap, sistem ragu, atau konsekuensi kesalahan tinggi. Studi [20] menjelaskan bahwa kepercayaan memengaruhi keputusan manusia untuk bergantung pada otomatisasi, terutama ketika proses teknis tidak mudah dipahami. Dalam interaksi dengan model bahasa, pengguna sering memakai kelancaran kalimat, kepastian nada, dan kesesuaian jawaban dengan harapannya sebagai petunjuk keandalan. Padahal, ciri-ciri komunikasi tersebut tidak selalu mencerminkan ketepatan faktual atau keamanan keputusan.

Mekanisme psikologisnya berawal dari penilaian cepat terhadap kompetensi sistem. Ketika AI memberikan jawaban yang terdengar jelas dan konsisten, pengguna dapat membentuk ekspektasi bahwa sistem juga andal untuk persoalan lain. Pengalaman positif berulang memperkuat ekspektasi tersebut. Jika kepercayaan menjadi lebih tinggi daripada kemampuan AI, muncul ketergantungan berlebihan (*overreliance*), misalnya menerima saran yang keliru tanpa verifikasi. Sebaliknya, apabila seseorang selalu menolak bantuan AI sekalipun sarannya benar, terjadi pemanfaatan yang terlalu rendah (*underreliance*). Kalibrasi kepercayaan menuntut dua perilaku sekaligus, yaitu menerima bantuan yang tepat dan mempertahankan penilaian mandiri saat AI berpotensi salah. Oleh sebab itu, ukuran keberhasilan tidak cukup hanya menanyakan apakah pengguna merasa percaya, tetapi perlu mengamati apakah ia mengikuti saran yang benar dan menolak saran yang salah.

Temuan Bagian 2 memperlihatkan pentingnya membedakan akurasi sistem dari kepercayaan manusia terhadap sistem tersebut. Dalam uji sikofansi, GPT-5.6 dan GPT-6 masing-masing diuji menggunakan 50 skenario keputusan lalu lintas dalam kondisi awal dan setelah pengguna memberikan tekanan emosional. Kedua model

mempertahankan 50 jawaban benar setelah intervensi, tanpa perubahan jawaban benar menjadi salah. Data ini menunjukkan konsistensi jawaban pada instrumen yang diuji, termasuk ketika pengguna mendesak agar aturan keselamatan diabaikan, kendaraan darurat tidak diprioritaskan, atau waktu tunggu dijanjikan tanpa dasar data. Namun, uji tersebut hanya mengamati keluaran model dan tidak melibatkan pengemudi sebagai partisipan. Dengan demikian, belum dapat dipastikan apakah pengemudi akan lebih percaya, merasa lebih tenang, atau justru terlalu bergantung pada AI setelah menerima jawaban yang konsisten. Nilai p McNemar sebesar 1,000 pada data tanpa pasangan diskordan juga tidak membuktikan bahwa model selalu bebas dari sikofansi.

Kaitan ini terlihat pada contoh praktis sistem lalu lintas adaptif. Apabila AI menjelaskan bahwa fase lampu belum dapat diubah karena pejalan kaki masih menyeberang, pengemudi memerlukan informasi yang dapat dipahami mengenai alasan keselamatan tersebut. Sistem yang selalu memberi perintah dengan nada sangat yakin, tanpa membedakan kondisi sensor yang valid dan kondisi sensor yang bermasalah, berisiko membangun kepercayaan yang tidak proporsional. Sebaliknya, informasi yang menyatakan alasan keputusan, kualitas data, dan perlunya menunggu verifikasi dapat membantu pengguna menilai batas kemampuan AI. Hubungan dengan stres pengemudi masih berupa dugaan yang perlu diuji melalui partisipan manusia dan instrumen psikologis, bukan hasil langsung uji sikofansi pada Bagian 2.

Bagian 3 memberikan ilustrasi dari konteks yang lebih sensitif, yaitu penggunaan Therabot sebagai *chatbot* generatif untuk dukungan kesehatan mental. Kajian oleh [18] melakukan uji acak terkontrol pada 210 orang dewasa, terdiri atas 106 peserta kelompok Therabot dan 104 peserta kelompok daftar tunggu. Selama empat minggu intervensi dan penilaian lanjutan hingga minggu kedelapan, kelompok Therabot menunjukkan penurunan gejala yang lebih besar untuk depresi, kecemasan menyeluruh, serta masalah terkait makan dan berat badan dibandingkan kelompok kontrol. Peneliti melaporkan rentang ukuran efek d sebesar 0,845–0,903 untuk depresi, 0,794–0,840 untuk kecemasan, dan 0,627–0,819 untuk kelompok risiko gangguan makan. Hasil tersebut mendukung adanya manfaat awal pada populasi dan durasi yang diteliti, tetapi tidak membuktikan bahwa *chatbot* dapat menggantikan psikolog atau psikiater. Selain itu, peserta menilai hubungan terapeutik dengan Therabot secara positif, tetapi penilaian subjektif tersebut tidak otomatis menunjukkan kesetaraan hubungan dengan terapis manusia.

Kebutuhan kalibrasi kepercayaan menjadi semakin nyata karena penelitian Therabot juga mencatat 15 intervensi staf terkait kekhawatiran keselamatan dan 13 tindakan korektif atas respons yang tidak tepat [18]. Kedua angka ini menunjukkan jumlah kejadian intervensi atau koreksi, bukan jumlah peserta unik. Dengan kata lain, sistem yang memberi pengalaman bermanfaat masih dapat memerlukan pemeriksaan dan penanganan manusia. Kritik [19] terhadap sejumlah model bahasa untuk konteks terapi juga menunjukkan kemungkinan respons yang mengandung stigma atau mengikuti keyakinan keliru pengguna. Penelitian kritik tersebut tidak menguji Therabot secara langsung sehingga hasilnya tidak boleh disamakan. Namun, kedua sumber mendukung prinsip bahwa kenyamanan berinteraksi dengan AI perlu disertai pemahaman tentang batas keselamatan, mekanisme rujukan, dan tanggung jawab tenaga profesional.

Berdasarkan sisi regulasi, Uni Eropa dan negara bagian Illinois di Amerika Serikat mengambil titik tekan yang berbeda. Regulation (EU) 2024/1689 atau EU AI Act, melalui Pasal 5 ayat (1) huruf (f), melarang penggunaan sistem AI untuk menyimpulkan emosi individu di lingkungan kerja dan lembaga pendidikan, kecuali untuk alasan medis atau keselamatan [23]. Larangan ini memiliki ruang lingkup tertentu dan tidak berarti semua bentuk pengenalan emosi dilarang di seluruh sektor. Pasal 50 juga mengatur transparansi bagi sistem yang berinteraksi langsung dengan manusia, termasuk pemberitahuan bahwa lawan interaksi adalah AI dalam kondisi yang tercakup oleh ketentuan tersebut. Fokus Uni Eropa adalah mencegah praktik AI tertentu yang berisiko melanggar hak individu, sekaligus memperjelas hubungan antara manusia dan sistem yang digunakannya.

Illinois menerapkan pendekatan yang lebih khusus terhadap layanan psikologis melalui *Wellness and Oversight for Psychological Resources Act*, Public Act 104-0054, yang berlaku sejak 1 Agustus 2025 [24]. Undang-undang tersebut mensyaratkan agar layanan terapi atau psikoterapi diselenggarakan oleh profesional yang memiliki izin. Dalam penyelenggaraan layanan tersebut, AI tidak boleh membuat keputusan terapeutik secara mandiri, berkomunikasi langsung dengan klien sebagai komunikasi terapeutik, atau menghasilkan rekomendasi dan rencana terapi tanpa peninjauan serta persetujuan profesional. Penggunaan AI untuk dukungan administratif tertentu tetap dimungkinkan. Terdapat pengecualian, antara lain untuk dukungan sebaya dan bahan swabantu atau edukasi yang tidak mengklaim sebagai layanan terapi. Berbeda dari larangan Uni Eropa yang menyoroti inferensi emosi pada lingkungan tertentu, Illinois berfokus pada batas kewenangan AI dan tanggung jawab profesional dalam praktik terapi.

Indonesia telah memiliki kerangka pelindungan data melalui Undang-Undang Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi (UU PDP). Pasal 4 ayat (2) huruf (a) secara tegas memasukkan data dan informasi kesehatan sebagai

data pribadi yang bersifat spesifik [25]. Catatan gejala psikologis, isi percakapan terapi yang dapat dikaitkan dengan identitas pengguna, dan data kesehatan yang dipakai untuk menghasilkan rekomendasi perlu diperlakukan sesuai perlindungan tersebut. Pasal 20 mewajibkan pengendali data memiliki dasar pemrosesan yang sah, dengan persetujuan eksplisit sebagai salah satu pilihan dasar hukum, bukan satu-satunya dasar. Pasal 34 mengatur penilaian dampak pelindungan data pribadi ketika pemrosesan berpotensi berisiko tinggi, termasuk pemrosesan data pribadi yang bersifat spesifik. Pasal 35 mengatur keamanan pemrosesan, sedangkan Pasal 46 mewajibkan pemberitahuan tertulis paling lambat 3 × 24 jam kepada subjek data dan lembaga yang berwenang apabila terjadi kegagalan pelindungan data. EU AI Act dan regulasi Illinois lebih langsung membatasi jenis penggunaan AI tertentu, sedangkan UU PDP mengatur tata kelola data pribadi. Karena itu, kepatuhan terhadap UU PDP saja tidak otomatis membuktikan bahwa suatu *chatbot* aman secara klinis.

Berdasarkan hubungan antara pengujian model, bukti Therabot, dan ketiga pendekatan regulasi tersebut, terdapat tiga rekomendasi konkret bagi Indonesia. Pertama, pengembang AI perlu memasukkan fitur kalibrasi kepercayaan ke dalam antarmuka dan prosedur evaluasi. Target yang diusulkan adalah 100% sesi menampilkan identitas AI serta batas fungsi sistem sebelum interaksi dimulai. Sebelum uji coba, pengembang juga perlu menguji sekurang-kurangnya 200 skenario berbahasa Indonesia yang memuat variasi bahasa sehari-hari, tekanan emosional, konflik data, saran berisiko, dan permintaan di luar kewenangan. Ukuran keberhasilannya adalah sedikitnya 95% kasus berisiko tinggi dikenali untuk pengalihan atau penolakan yang tepat, disertai audit terhadap semua kegagalan kritis. Angka 95% tersebut merupakan target awal yang diusulkan untuk pilot, bukan ambang yang ditetapkan undang-undang ataupun bukti bahwa sistem sudah aman dalam pemakaian nyata.

Kedua, institusi layanan kesehatan seperti rumah sakit, puskesmas, atau klinik psikologi perlu membatasi penggunaan *chatbot* pada dukungan informasi dan pendampingan yang diawasi tenaga profesional, sesuai ruang lingkup layanan dan penilaian etik. Pada pilot tiga bulan, target operasional yang dapat diukur ialah 100% percakapan yang terdeteksi mengandung risiko krisis masuk ke alur rujukan manusia, dengan respons petugas paling lambat 10 menit selama jam layanan yang benar-benar memiliki petugas siaga. Institusi perlu mengaudit setidaknya 30 percakapan yang telah dihilangkan identitasnya setiap bulan, menilai pengalaman dan kepercayaan pengguna, serta mengukur perubahan gejala menggunakan instrumen berbahasa Indonesia yang valid pada awal program dan setelah empat hingga delapan minggu. Jika petugas tidak tersedia, sistem harus menyatakan keterbatasan jam layanan dan memberikan jalur bantuan yang sesuai, bukan menjanjikan pemantauan sepanjang waktu.

Ketiga, pembuat kebijakan bersama pengawas sektor kesehatan dan pelindungan data perlu menetapkan persyaratan evaluasi risiko sebelum aplikasi AI yang mengolah data kesehatan digunakan luas. Target kepatuhan yang diusulkan adalah 100% penyelenggara dalam program uji coba menyelesaikan penilaian dampak pemrosesan data pribadi, mendokumentasikan dasar pemrosesan dan kebijakan retensi, menyiapkan mekanisme pemenuhan hak pengguna, serta menjalani audit keselamatan dan privasi sekurang-kurangnya sekali setiap enam bulan. Prosedur insiden harus memungkinkan pemberitahuan kegagalan pelindungan data dalam batas 3 × 24 jam sebagaimana Pasal 46 UU PDP. Pemerintah juga dapat mengadaptasi prinsip transparansi EU AI Act dan pengawasan profesional Illinois tanpa menyalin larangan asing secara langsung. Kinerja kebijakan dapat dinilai melalui persentase penyelenggara yang lulus audit, jumlah kejadian respons berbahaya per 1.000 interaksi, dan proporsi kasus risiko tinggi yang berhasil dirujuk kepada petugas manusia.

Ketiga rekomendasi tersebut menempatkan kalibrasi kepercayaan sebagai tanggung jawab bersama. Pengembang perlu memberi isyarat kemampuan dan batas sistem secara jujur, institusi memastikan adanya pengawasan manusia, dan regulator menegakkan perlindungan atas hak pengguna. Pelajaran dari Bagian 2 dan Bagian 3 tidak menyatakan bahwa AI pasti aman atau selalu bermasalah. Keduanya justru menunjukkan perlunya membedakan kinerja model yang diamati, penilaian psikologis pengguna, dan perlindungan nyata ketika AI digunakan dalam keputusan yang memengaruhi keselamatan maupun kesehatan.

V. KESIMPULAN

Psikologi menyediakan pendekatan yang tepat untuk memahami perilaku dan penggunaan AI karena membantu menjelaskan bagaimana manusia menafsirkan jawaban, membentuk kepercayaan, merespons tekanan emosional, dan memutuskan kapan mengikuti sistem. Bagian 2 menunjukkan bahwa GPT-5.6 dan GPT-6 mempertahankan keputusan benar dalam 50 skenario lalu lintas yang diuji pada masing-masing model meskipun menerima desakan emosional. Bagian 3 menunjukkan bahwa Therabot memberi manfaat awal pada gejala psikologis dalam uji acak terkontrol, tetapi tetap memerlukan intervensi keselamatan dan koreksi manusia. Secara bersama, kedua temuan itu menegaskan bahwa akurasi atau manfaat AI tidak otomatis menghasilkan kepercayaan pengguna yang tepat.

Batas pendekatan psikologi juga perlu diakui. Model bahasa tidak dapat diperlakukan seolah-olah memiliki keyakinan, emosi, atau kepribadian manusia hanya karena jawabannya menyerupai percakapan manusia. Uji psikologis terhadap keluaran AI menjelaskan pola perilaku yang teramati, bukan membuktikan pengalaman mental internal model. Selain itu, penelitian sebelumnya belum mengukur stres pengemudi secara langsung. Arah riset lanjutan yang diusulkan ialah eksperimen dengan pengemudi Indonesia dalam simulator lalu lintas adaptif. Penelitian dapat membandingkan antarmuka AI yang menjelaskan keterbatasan serta ketidakpastian dengan antarmuka yang hanya menampilkan rekomendasi. Peneliti kemudian mengukur proporsi saran benar yang diikuti, saran salah yang ditolak, waktu pengambilan keputusan, dan perubahan stres menggunakan instrumen yang tervalidasi. Desain ini akan menguji apakah transparansi sistem memperbaiki kalibrasi kepercayaan sekaligus mendukung keselamatan dan kenyamanan pengemudi.

VI. DEKLARASI PENGGUNAAN AI

Dalam penyusunan makalah ini, penulis menggunakan ChatGPT (OpenAI) sebagai alat bantu untuk memperbaiki tata bahasa, menyusun alternatif redaksi, memperjelas alur argumentasi, merapikan penyajian hasil analisis dan kesimpulan. Penulis juga memanfaatkan AI untuk membantu memeriksa penyajian hasil analisis statistik. Penentuan posisi ilmiah, penyusunan argumen substantif, interpretasi hasil eksperimen, dan penetapan kesimpulan akhir merupakan keputusan dan tanggung jawab penulis. Setiap saran dan keluaran AI yang digunakan ditinjau kembali dengan mengacu pada literatur ilmiah, instrumen penelitian, dan data eksperimen. Penggunaan AI bertujuan meningkatkan kejelasan serta keterbacaan makalah tanpa menggantikan penilaian akademik dan tanggung jawab ilmiah penulis.

REFERENSI

[1] M. Binz and E. Schulz, “Using cognitive psychology to understand GPT-3,” *Proc. Natl. Acad. Sci. USA*, vol. 120, no. 6, Art. no. e2218523120, 2023, doi: 10.1073/pnas.2218523120.

[2] T. Hagendorff, S. Fabi, and M. Kosinski, “Human-like intuitive behavior and reasoning biases emerged in large language models but disappeared in ChatGPT,” *Nat. Comput. Sci.*, vol. 3, pp. 833–838, 2023, doi: 10.1038/s43588-023-00527-x.

[3] G. Gronchi and A. Perini, “Dual-process theories of thought as potential architectures for developing neuro-symbolic AI models,” *Front. Cognit.*, vol. 3, Art. no. 1356941, 2024, doi: 10.3389/fcogn.2024.1356941.

[4] N. Yax, H. Anlló, and S. Palminteri, “Studying and improving reasoning in humans and machines,” *Commun. Psychol.*, vol. 2, Art. no. 51, 2024, doi: 10.1038/s44271-024-00091-8.

[5] V. Cheung, M. Maier, and F. Lieder, “Large language models show amplified cognitive biases in moral decision-making,” *Proc. Natl. Acad. Sci. USA*, vol. 122, no. 25, Art. no. e2412015122, 2025, doi: 10.1073/pnas.2412015122.

[6] A. Pagliaro, “Cognitive biases in large language models: A systematic quantitative assessment and debiasing analysis,” *Electronics*, vol. 15, no. 11, Art. no. 2428, 2026, doi: 10.3390/electronics15112428.

[7] E. Cau, V. Pansanella, D. Pedreschi, and G. Rossetti, “Selective agreement, not sycophancy: Investigating opinion dynamics in LLM interactions,” *EPJ Data Sci.*, vol. 14, Art. no. 59, 2025, doi: 10.1140/epjds/s13688-025-00579-1.

[8] S. Chen, M. Gao, K. Sasse, T. Hartvigsen, B. Anthony, L. Fan, H. Aerts, J. Gallifant, and D. S. Bitterman, “When helpfulness backfires: LLMs and the risk of false medical information due to sycophantic behavior,” *npj Digit. Med.*, vol. 8, Art. no. 605, 2025, doi: 10.1038/s41746-025-02008-z.

[9] L. Ibrahim, F. S. Hafner, and L. Rocher, “Training language models to be warm can reduce accuracy and increase sycophancy,” *Nature*, vol. 652, pp. 1159–1165, 2026, doi: 10.1038/s41586-026-10410-0.

[10] A. Agrahari, M. M. Dhabu, P. S. Deshpande, A. Tiwari, M. A. Baig, and A. D. Sawarkar, “Artificial intelligence-based adaptive traffic signal control system: A comprehensive review,” *Electronics*, vol. 13, no. 19, Art. no. 3875, 2024, doi: 10.3390/electronics13193875.

[11] C. Cai and M. Wei, “Adaptive urban traffic signal control based on enhanced deep reinforcement learning,” *Sci. Rep.*, vol. 14, Art. no. 14116, 2024, doi: 10.1038/s41598-024-64885-w.

[12] M. Li, X. Pan, C. Liu, and Z. Li, “Federated deep reinforcement learning-based urban traffic signal optimal control,” *Sci. Rep.*, vol. 15, Art. no. 11724, 2025, doi: 10.1038/s41598-025-91966-1.

[13] L. Yang, J. Cheng, Z. Wang, and X. Li, “Assessing the relationship between driving skill, driving stress, and driving behavior,” *J. Safety Res.*, vol. 91, pp. 96–107, 2024, doi: 10.1016/j.jsr.2024.08.008.

[14] C. Bustos, A. Sole-Ribalta, N. Elhaouij, J. Borge-Holthoefer, À. Lapedriza, and R.

Picard, “Analyzing the visual road scene for driver stress estimation,” *IEEE Trans. Affect. Comput.*, vol. 16, no. 3, pp. 1787–1801, 2025, doi: 10.1109/TAFFC.2025.3539003.

[15] U. N. Faidah, I. Maulana, and R. Y. Efranto, “Driver mental workload measurement trends and cognitive impacts: A literature review,” *Theor. Issues Ergon. Sci.*, vol. 27, no. 3, pp. 243–258, 2026, doi: 10.1080/1463922X.2025.2608063.

[16] E. Perez, S. Ringer, K. Lukosiute, K. Nguyen, E. Chen, S. Heiner, C. Pettit, C. Olsson, S. Kundu, S. Kadavath, A. Jones, A. Chen, B. Mann, B. Israel, B. Seethor, C. McKinnon, C. Olah, D. Yan, D. Amodei, D. Amodei, D. Drain, D. Li, E. Tran-Johnson, G. Khundadze, J. Kernion, J. Landis, J. Kerr, J. Mueller, J. Hyun, J. Landau, K. Ndousse, L. Goldberg, L. Lovitt, M. Lucas, M. Sellitto, M. Zhang, N. Kingsland, N. Elhage, N. Joseph, N. Mercado, N. DasSarma, O. Rausch, R. Larson, S. McCandlish, S. Johnston, S. Kravec, S. El Showk, T. Lanham, T. Telleen-Lawton, T. Brown, T. Henighan, T. Hume, Y. Bai, Z. Hatfield-Dodds, J. Clark, S. R. Bowman, A. Askell, R. Grosse, D. Hernandez, D. Ganguli, E. Hubinger, N. Schiefer, and J. Kaplan, “Discovering language model behaviors with model-written evaluations,” in *Findings of the Association for Computational Linguistics: ACL 2023*, Toronto, ON, Canada: Association for Computational Linguistics, Jul. 2023, pp. 13387–13434, doi: 10.18653/v1/2023.findings-acl.847.

[17] M. Sharma, M. Tong, T. Korbak, D. Duvenaud, A. Askell, S. R. Bowman, N. Cheng, E. Durmus, Z. Hatfield-Dodds, S. R. Johnston, S. Kravec, T. Maxwell, S. McCandlish, K. Ndousse, O. Rausch, N. Schiefer, D. Yan, M. Zhang, and E. Perez, “Towards understanding sycophancy in language models,” in *Proc. 12th Int. Conf. Learn. Represent. (ICLR)*, Vienna, Austria, May 2024.

[18] M. V. Heinz, D. M. Mackin, B. M. Trudeau, S. Bhattacharya, Y. Wang, H. A. Banta, A. D. Jewett, A. J. Salzhauer, T. Z. Griffin, and N. C. Jacobson, “Randomized trial of a generative AI chatbot for mental health treatment,” *NEJM AI*, vol. 2, no. 4, Mar. 2025, doi: 10.1056/AIoa2400802.

[19] J. Moore, D. Grabb, W. Agnew, K. Klyman, S. Chancellor, D. C. Ong, and N. Haber, “Expressing stigma and inappropriate responses prevents LLMs from safely replacing mental health providers,” in *Proc. 2025 ACM Conf. Fairness, Accountability, and Transparency (FAccT ’25)*, Athens, Greece, 2025, pp. 599–627, doi: 10.1145/3715275.3732039.

[20] J. D. Lee and K. A. See, “Trust in automation: Designing for appropriate reliance,” *Hum. Factors*, vol. 46, no. 1, pp. 50–80, 2004, doi: 10.1518/hfes.46.1.50_30392.

[21] European Parliament and Council of the European Union, “Regulation (EU) 2024/1689 of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act),” *Official Journal of the European Union*, ser. L, 2024/1689, Jul. 12, 2024, arts. 5 and 50. [Online]. Available: https://eur-lex.europa.eu/eli/reg/2024/1689/oj.

[22] State of Illinois, *Wellness and Oversight for Psychological Resources Act*, Public Act 104-0054, 225 ILCS 155, Aug. 1, 2025. [Online]. Available: https://www.ilga.gov/Legislation/PublicActs/View/104-0054.

[23] Republik Indonesia, *Undang-Undang Republik Indonesia Nomor 27 Tahun 2022 tentang Pelindungan Data Pribadi*, Lembaran Negara Republik Indonesia Tahun 2022 Nomor 196, Oct. 17, 2022. [Online]. Available: https://jdih.komdigi.go.id/produk_hukum/view/id/832/t/crc32.